

Normas, estabilidade e condicionamento de sistemas de equações lineares

• Normas de vetores

- Uma *norma* num espaço vetorial é o equivalente ao módulo na reta dos reais: ela provê uma medida do *comprimento* de um vetor.
- Mais precisamente, um espaço vetorial \mathbb{R}^n e uma norma em \mathbb{R}^n definem um espaço métrico.
- **Def.:** uma norma vetorial em \mathbb{R}^n é uma função

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

que satisfaz as seguintes propriedades:

$$f(x) \geq 0 \mid x \in \mathbb{R}^n$$

$$f(x + y) \leq f(x) + f(y) \quad \forall x, y \in \mathbb{R}^n$$

$$f(\alpha x) = |\alpha|f(x) \quad \forall \alpha \in \mathbb{R}, x \in \mathbb{R}^n$$

- Normas de vetores

- Uma função que satisfaça essas propriedades é denominada de **norma** e é indicada por

$$f(x) = \|x\|_k$$

onde o índice indica uma norma específica, a saber:

$$\|x\|_1 = |x_1| + \cdots + |x_n|, \quad (1)$$

$$\|x\|_2 = \sqrt{x_1^2 + \cdots + x_n^2}, \quad (2)$$

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|. \quad (3)$$

- Do ponto de vista computacional, a norma $\|x\|_\infty$ é a mais facilmente calculada e a que preserva a informação numérica presente nos elementos de x , já que nenhuma operação aritmética é efetuada (logo, não há erros de arredondamento).

- Normas de vetores

- Já o cálculo da norma $\|x\|_2$ deve ser feito com extremo cuidado, pois dependendo das magnitudes dos elementos de x , é possível que haja uma acumulação catastrófica de erros de arredondamento.
- Na biblioteca BLAS, a FUNCTION _NRM2 efetua o cálculo dessa norma efetuando multiplicações, por fatores de escala adequados, dos termos no somatório dos elementos de x ao quadrado.

- Normas de vetores

- A função `norma_2`, escrita em SciLab, implementa o algoritmo presente na BLAS DNRM2:

```
function v=norma_2(x)
    n=max(size(x))
    if n==1
        v=abs(x(1))
    else
        scale = 0.0
        ssq = 1.0
        for i=1:n
            if x(i)~=0.0
                absxi = abs(x(i))
                if scale<absxi
                    ssq = 1.0+ssq*(scale/absxi)^2
                    scale = absxi
                else
                    ssq = ssq+(absxi/scale)^2
                end
            end
        end
        v = scale*sqrt(ssq)
    end
endfunction
```

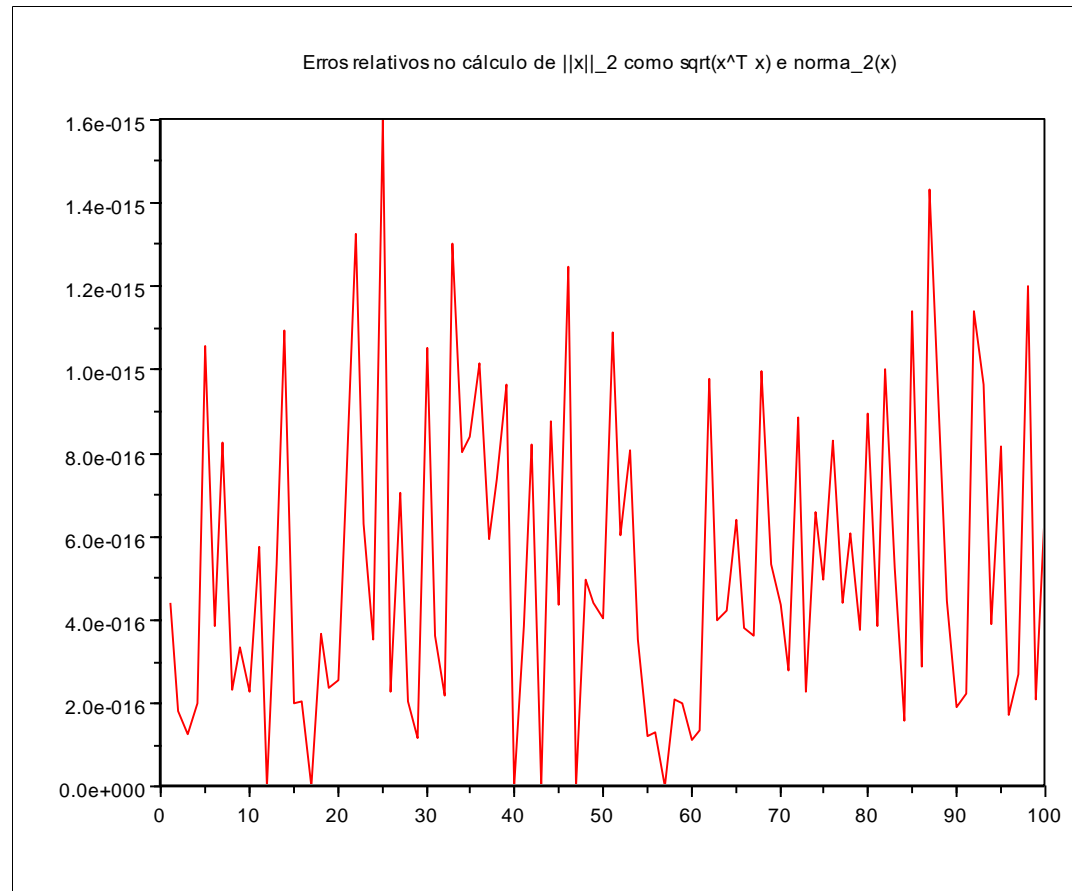
- Normas de vetores

- Para verificarmos a diferença entre o cálculo dessa norma usando a Eq. (2) e usando a rotina *norma_2*, calculamos 100 vezes essa norma das duas formas acima, sobre vetores cujos elementos foram gerados aleatoriamente e com magnitudes diferentes:

```
for i=1:100
    x=rand(1000,1,'normal');
    x(20:120,1)=x(20:120,1)/rand(1,1,'normal');
    x(500:599,1)=rand(1,1,'normal')*x(500:599,1);
    ingenua=sqrt(x'*x);
    cuidadosa=norma_2(x);
    erro_relativo(i)=abs(cuidadosa-ingenua)/cuidadosa;
end
plot(1:1:100,erro_relativo,'r-')
```

- Normas de vetores

Observe que um erro relativo da ordem de 10^{-15} pode causar diferenças em cálculos posteriores!



Normas, estabilidade e condicionamento de sistemas de equações lineares

- Normas de vetores

- Todas as normas em \mathbb{R}^n são equivalentes, i.e. existem duas constantes positivas c_1 e c_2 tais que

$$c_1 \|x\|_\alpha \leq \|x\|_\beta \leq c_2 \|x\|_\alpha \mid x \in \mathbb{R}^n \quad (4)$$

- Por exemplo,

$$\|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2 \quad (5)$$

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n} \|x\|_\infty \quad (6)$$

$$\|x\|_\infty \leq \|x\|_1 \leq n \|x\|_\infty \quad (7)$$

- Normas de vetores

- Com as normas, podemos definir os *erros absoluto e relativo* entre dois vetores $x, y \in \mathbb{R}^n$ como

$$e_a = \|x - y\| \quad (8)$$

$$e_r = \frac{\|x - y\|}{\|x\|}, x \neq 0 \quad (9)$$

- Para o caso particular da norma $\|x\|_\infty$, o erro relativo nos permite estimar o número de dígitos significativos exatos entre dois vetores, sujeitos a uma tolerância $\tau \ll 1$:

$$-\log_{10} \frac{\|x - y\|_\infty}{\|x\|_\infty} \leq -\log_{10} \tau \quad (10)$$

- Normas de vetores

- O lado esquerdo da desigualdade é conhecido pela sigla DIGSE (Dígitos Significativos Exatos):

$$DIGSE = -\log_{10} \frac{\|x - y\|_{\infty}}{\|x\|_{\infty}}. \quad (11)$$

o qual nos permite estimar quantos dígitos significativos exatos há em y (observe que deve-se considerar apenas a parte inteira do valor calculado).

- Nota: uma expressão equivalente permite calcular a quantidade de dígitos significativos exatos entre $x, y \in \mathbb{R}$:

$$DIGSE = -\log_{10} \frac{|x - y|}{|x|} \quad (12)$$

- Normas de vetores

- Por exemplo, se x e y são dois vetores em \mathbb{R}^2 , com pequenas diferenças entre os valores dos seus elementos,

$$x = \begin{bmatrix} 1,23500 \\ 0,05128 \end{bmatrix}, y = \begin{bmatrix} 1,23400 \\ 0,05674 \end{bmatrix}$$

e se calcularmos

$$x - y = \begin{bmatrix} 0,00100 \\ -0,00546 \end{bmatrix}$$

então

$$DIGSE = -\log_{10} \frac{\|x - y\|_{\infty}}{\|x\|_{\infty}} = -\log_{10} \frac{0,00546}{1,23500} = 2,35$$

o que indica que y tem 2 dígitos significativos exatos.

- Normas de vetores

- As normas de matrizes são definidas em termos das normas de vetores.
- As normas de matrizes nos permitem dizer, por exemplo, quando uma matriz é “quase-singular”.
- **Def.:** uma norma matricial em $\mathbb{R}^{m \times n}$ é uma função
$$f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$$

que satisfaz as seguintes propriedades:

$$f(\mathbf{A}) \geq 0 \mid \mathbf{A} \in \mathbb{R}^{m \times n}$$

$$f(\mathbf{A} + \mathbf{B}) \leq f(\mathbf{A}) + f(\mathbf{B}) \forall \mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$$

$$f(\alpha \mathbf{A}) = |\alpha| f(\mathbf{A}) \forall \alpha \in \mathbb{R}, \mathbf{A} \in \mathbb{R}^{m \times n}$$

- Normas de matrizes

- As mais utilizadas são a **norma de Frobenius**,

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{i,j}^2} \quad (13)$$

e a **norma- p** :

$$\|A\|_p = \sup_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\|x\|_p=1} \|Ax\|_p, x \in \mathbb{R}^n. \quad (14)$$

- É importante considerar que as duas normas acima definem, na verdade, *famílias* de normas, já que a norma-2 em $\mathbb{R}^{m \times n}$ é uma função *diferente* da norma-2 em $\mathbb{R}^{p \times q}$.

• Normas de matrizes

- Observe que nem todas as normas matriciais satisfazem a *propriedade submultiplicativa*: $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|$
- Algumas propriedades importantes:

$$\|\mathbf{Ax}\|_p \leq \|\mathbf{A}\|_p \cdot \|x\|_p, \mathbf{A} \in \mathbb{R}^{m \times n}, x \in \mathbb{R}^n \quad (15)$$

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{n} \|\mathbf{A}\|_2 \quad (16)$$

$$\max_{i,j} |a_{i,j}| \leq \|\mathbf{A}\|_2 \leq \sqrt{mn} \max_{i,j} |a_{i,j}| \quad (17)$$

$$\frac{1}{\sqrt{n}} \|\mathbf{A}\|_\infty \leq \|\mathbf{A}\|_2 \leq \sqrt{m} \|\mathbf{A}\|_\infty \quad (18)$$

$$\frac{1}{\sqrt{m}} \|\mathbf{A}\|_1 \leq \|\mathbf{A}\|_2 \leq \sqrt{n} \|\mathbf{A}\|_1 \quad (19)$$

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{i,j}| \quad (20)$$

$$\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{i,j}| \quad (21)$$

- Normas de matrizes

- Para a norma- p com $p = 2$, um teorema nos diz que existe um vetor z , tal que $\|z\|_2 = 1$, para o qual

$$A^T A z = \|A\|_2^2 z \quad (22)$$

- Observe que se escrevermos esse resultado na forma

$$B v = \lambda v$$

o teorema está nos dizendo que o quadrado da norma-2 de A é uma das raízes do polinômio característico,

$$\det(A^T A - \lambda I).$$

- Um corolário desse teorema nos permite estimar a norma-2 de A através das normas $p = 1$ e $p = \infty$:

$$\|A\|_2 \leq \sqrt{\|A\|_1 \|A\|_\infty}. \quad (23)$$

• Normas de matrizes

- Vamos analisar dois problemas relativos à *perturbação* – causada pelos erros de arredondamento – dos elementos de uma matriz \mathbf{A} .
- O primeiro é quantificar o quanto a sua inversa, \mathbf{A}^{-1} , muda, quando alguns elementos de \mathbf{A} são alterados.
- **Lema:** Suponha $\mathbf{F} \in \mathbb{R}^{n \times n}$ e que $\|\cdot\|$ é uma norma que satisfaz a propriedade submultiplicativa. Se $\|\mathbf{F}\| < 1$, então $\mathbf{I} - \mathbf{F}$ não é singular e

$$(\mathbf{I} - \mathbf{F})^{-1} = \sum_{k=0}^{\infty} \mathbf{F}^k, \quad (24)$$

$$\|(\mathbf{I} - \mathbf{F})^{-1}\| \leq \frac{1}{1 - \|\mathbf{F}\|}. \quad (25)$$

• Normas de matrizes

• Prova:

- a) Suponha que $\mathbf{I} - \mathbf{F}$ é singular. Então, $(\mathbf{I} - \mathbf{F})\mathbf{x} = \mathbf{0}$, para algum $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{x} \neq \mathbf{0}$. Porém, daí podemos escrever $\|\mathbf{x}\| = \|\mathbf{F}\mathbf{x}\|$, de onde $\|\mathbf{F}\| \geq 1$, o que é uma contradição. Logo, $\mathbf{I} - \mathbf{F}$ não é singular. ■
- b) Para a inversa $(\mathbf{I} - \mathbf{F})^{-1}$, considere a identidade

$$\left(\sum_{k=0}^N \mathbf{F}^k \right) (\mathbf{I} - \mathbf{F}) = \mathbf{I} - \mathbf{F}^{N+1}.$$

Como $\|\mathbf{F}\| < 1 \rightarrow \|\mathbf{F}^k\| < \|\mathbf{F}\|^k$, temos que $\lim_{k \rightarrow \infty} \mathbf{F}^k = \mathbf{0}$. Logo, $\left(\lim_{N \rightarrow \infty} \sum_{k=0}^N \mathbf{F}^k \right) (\mathbf{I} - \mathbf{F}) = \mathbf{I}$ e, portanto, $(\mathbf{I} - \mathbf{F})^{-1} = \left(\lim_{N \rightarrow \infty} \sum_{k=0}^N \mathbf{F}^k \right)$.

• Normas de matrizes

• Prova:

- b) (cont.) Tomando normas dos dois lados da igualdade, podemos escrever

$$\|(I - F)^{-1}\| \leq \sum_{k=0}^{\infty} \|F^k\| = 1 + \|F\| + \|F\|^2 + \dots$$

E, chamando de S o lado direito da igualdade,

$$S = 1 + \|F\| + \|F\|^2 + \dots$$

$$S\|F\| = \|F\|^2 + \|F\|^3 + \dots$$

$$S - S\|F\| = 1 \rightarrow S = \frac{1}{1 - \|F\|}$$

Logo,

$$\|(I - F)^{-1}\| \leq \sum_{k=0}^{\infty} \|F^k\| = \frac{1}{1 - \|F\|} \cdot \blacksquare$$

- Normas de matrizes

- Observe que, como consequência do lema, podemos escrever

$$\|(I - F)^{-1} - I\| \leq \frac{\|F\|}{1 - \|F\|}. \quad (26)$$

- Esse resultado nos diz que, se I for perturbada, então perturbações de mesma ordem ocorrerão na inversa $(I - F)^{-1}$.

- Normas de matrizes

- **Teorema:** se A não é singular e $\|A^{-1}E\| = r < 1$, então $A + E$ também não é singular e

$$\|(A + E)^{-1} - A^{-1}\| \leq \frac{\|E\| \|A^{-1}\|^2}{1 - r}. \quad (27)$$

- *Prova:* como A não é singular, $A + E = A(I - F)$, onde $F = -A^{-1}E$. Como, por hipótese, $\|F\| = r < 1$, então $I - F$ não é singular e $\|(I - F)^{-1}\| = (1 - r)^{-1}$, pelo lema anterior. Agora, como $(A + E)^{-1} = (I - F)^{-1}A^{-1}$, podemos escrever

$$\|(A + E)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - r}$$

e, usando a identidade $B^{-1} = A^{-1} - B^{-1}(B - A)A^{-1}$, podemos escrever $(A + E)^{-1} - A^{-1} = -A^{-1}E(A + E)^{-1}$, de onde

$$\|(A + E)^{-1} - A^{-1}\| \leq \|A^{-1}\| \|E\| \|(A + E)^{-1}\| \leq \frac{\|E\| \|A^{-1}\|^2}{1 - r}. \blacksquare$$

- Normas de matrizes

- O segundo problema é quantificar os erros induzidos na solução de um sistema de equações lineares, quando A é perturbada.
- Suponha que se deseja resolver o sistema $Ax = b$, com A uma matriz não singular e que, ao armazenar o vetor b no computador, ocorreram erros de arredondamento, e o vetor armazenado é \tilde{b} .
- Podemos então comparar os erros relativos entre a solução x de $Ax = b$ e a solução \tilde{x} do sistema perturbado $A\tilde{x} = \tilde{b}$.

- Normas de matrizes

- O erro relativo $\|x - \tilde{x}\| \|x\|^{-1}$ pode ser medido escrevendo-se

$$\|x - \tilde{x}\| = \|A^{-1}b - A^{-1}\tilde{b}\| = \|A^{-1}(b - \tilde{b})\| \leq \|A^{-1}\| \|b - \tilde{b}\|.$$

- Como $Ax = b$, então tomando normas dos dois lados da igualdade, podemos escrever $\frac{\|Ax\|}{\|b\|} = 1$; se multiplicarmos o lado direito da desigualdade por essa razão, vem:

$$\|x - \tilde{x}\| \leq \|A^{-1}\| \|b - \tilde{b}\| = \|A^{-1}\| \|Ax\| \frac{\|b - \tilde{b}\|}{\|b\|}$$

Logo,

$$\|x - \tilde{x}\| \leq \|A^{-1}\| \|A\| \|x\| \frac{\|b - \tilde{b}\|}{\|b\|}$$

e

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \|A^{-1}\| \|A\| \frac{\|b - \tilde{b}\|}{\|b\|}. \quad (28)$$

- Normas de matrizes

- A expressão $\|A^{-1}\| \|A\|$, na Eq. (28), é denominada de **número de condição** de A ,

$$\boxed{\text{cond}(A) = \|A^{-1}\| \|A\|} \quad (29)$$

- Observando a Equação (28), podemos notar que o *erro relativo* entre o vetor b e sua representação em ponto-flutuante, \tilde{b} , é **multiplicado** pelo **número de condição** de A , ao se resolver o sistema perturbado $A\tilde{x} = \tilde{b}$.
- Logo, se $\text{cond}(A) \gg 1$, então os erros de arredondamento presentes em \tilde{b} poderão ser amplificados, de tal forma a tornar $\frac{\|x - \tilde{x}\|}{\|x\|}$ muito grande.

- Normas de matrizes

- Por exemplo: seja a matriz A e a sua inversa,

$$A = \begin{bmatrix} 1 & 1 + \varepsilon \\ 1 - \varepsilon & 1 \end{bmatrix}, A^{-1} = \frac{1}{\varepsilon^2} \begin{bmatrix} 1 & -1 - \varepsilon \\ -1 + \varepsilon & 1 \end{bmatrix}.$$

Calculando a norma- ∞ , vem

$$\|A\|_{\infty} = 2 + \varepsilon, \|A^{-1}\|_{\infty} = \frac{1}{\varepsilon^2} (2 + \varepsilon)$$

de onde

$$\text{cond}(A) = \left(\frac{2 + \varepsilon}{\varepsilon} \right)^2 > \frac{4}{\varepsilon^2}.$$

Se $\varepsilon \leq 10^{-2}$, então $\text{cond}(A) \geq 40000$; isso quer dizer que, se b sofrer uma perturbação da ordem de 10^{-8} , o erro relativo na solução do sistema poderá ser de até 4×10^{-4} , o que não pode ser desprezado!

- Normas de matrizes

- Finalmente, apresentamos um lema e um teorema que permitem estabelecer uma cota para o erro relativo entre as soluções de um sistema de equações lineares e um outro, cuja matriz de coeficientes e o termo independente tenham sido perturbados:

- Normas de matrizes

- **Lema:** Sejam os sistemas

$$Ax = b, A \in \mathbb{R}^{n \times n}, 0 \neq b \in \mathbb{R}^n$$

e

$$(A + \Delta A)y = b + \Delta b, \Delta A \in \mathbb{R}^{n \times n}, \Delta b \in \mathbb{R}^n,$$

tais que $\|\Delta A\| \leq \delta \|A\|$ e $\|\Delta b\| \leq \delta \|b\|$, com $\delta \in \mathbb{R}$. Se $\delta \times \text{cond}(A) = r < 1$, então $A + \Delta A$ não é singular e

$$\frac{\|y\|}{\|x\|} \leq \frac{1 + r}{1 - r}. \quad (30)$$

- **Teorema:** Se as condições do lema anterior são atendidas, então

$$\frac{\|x - y\|}{\|x\|} \leq \frac{2\delta}{1 - r} \text{cond}(A). \quad (31)$$